МИНОБРНАУКИ РОССИИ

САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ

ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ

«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)

Кафедра математического обеспечения и применения ЭВМ

ОТЧЕТ

по лабораторной работе №8

по дисциплине «Искусственные нейронные сети»

Тема: «Генерация текста на основе “Алисы в стране чудес”»

Студент гр. 8382 Ершов М.И.

Преподаватель Жангиров Т.Р.

Санкт-Петербург

2021

Цель работы.

Рекуррентные нейронные сети также могут быть использованы в качестве генеративных моделей.

Это означает, что в дополнение к тому, что они используются для прогнозных моделей (создания прогнозов), они могут изучать последовательности проблемы, а затем генерировать совершенно новые вероятные последовательности для проблемной области.

Подобные генеративные модели полезны не только для изучения того, насколько хорошо модель выявила проблему, но и для того, чтобы узнать больше о самой проблемной области.

Порядок выполнения работы.

1. Ознакомиться с генерацией текста;
2. Ознакомиться с системой Callback в Keras.

Требования.

1. Реализовать модель ИНС, которая будет генерировать текст;
2. Написать собственный CallBack, который будет показывать то как генерируется текст во время обучения (то есть раз в какое-то количество эпох генерировать и выводить текст у необученной модели);
3. Отследить процесс обучения при помощи TensorFlowCallBack, в отчете привести результаты и их анализ.

Ход работы.

Многие из классических текстов больше не защищены авторским правом. Это означает, что возможно скачать весь текст этих книг бесплатно и использовать их в экспериментах, например, при создании генеративных моделей. Возможно, лучшее место для получения доступа к бесплатным

книгам, которые больше не защищены авторским правом, это Проект Гутенберг.

В данной лабораторной работе будем использовать в качестве набора данных «Приключения Алисы в Стране Чудес» Льюиса Кэрролла. Мы собираемся изучить зависимости между символами и условные вероятности символов в последовательностях, чтобы мы могли, в свою очередь, генерировать совершенно новые и оригинальные последовательности символов.

Была построена нейронная сеть, разработанный код представлен в приложении А.

Была создана и обучена модель искусственной нейронной сети, решающая задачу генерации текста. Модель представлена на рис. 1.

```
model = Sequential()
model.add(LSTM(256, input_shape=(X.shape[1], X.shape[2])))
model.add(Dropout(0.2))
model.add(Dense(y.shape[1], activation='softmax'))
model.compile(loss='categorical_crossentropy', optimizer='adam')
```

Рисунок 1 – Модель нейронной сети.

Был написан собственный обратный вызов (CallBack), который позволит отслеживать то, как генерируется текст во время обучения, то есть в какое-то количество эпох генерировать и выводить текст у необученной модели:

```
class Mycallback(Callback):
    def __init__(self, epochs):
        super(Mycallback, self).__init__()
        self.epochs = epochs

    def on_epoch_end(self, epoch, logs=None):
        if epoch in self.epochs:
            random_generate(self.model, epoch)
```

Отследим процесс обучения и рассмотрим тексты сгенерированные после 7, 12, 22 и 30 эпох.

После седьмой эпохи сеть сгенерировала пустая последовательность, которая продемонстрирована на рис. 2

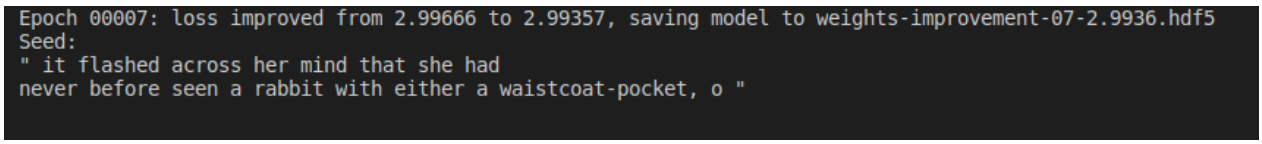

Рисунок 2 – Результат после 7 эпохи.

После 12 эпохи сеть сгенерировала повторяющуюся последовательность. Результат показан на рис. 3.

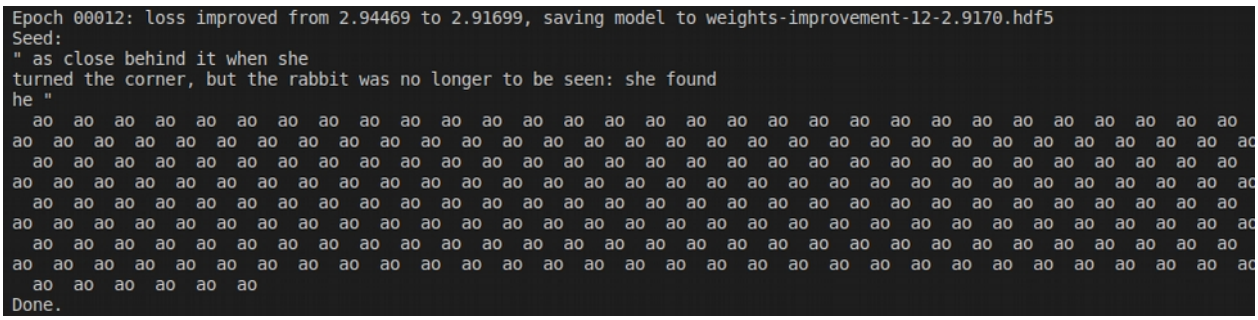

Рисунок 3 – Результат после 12 эпохи.

После 22 эпохи сеть сгенерировала опять повторяющуюся последовательность, но уже большей длины.

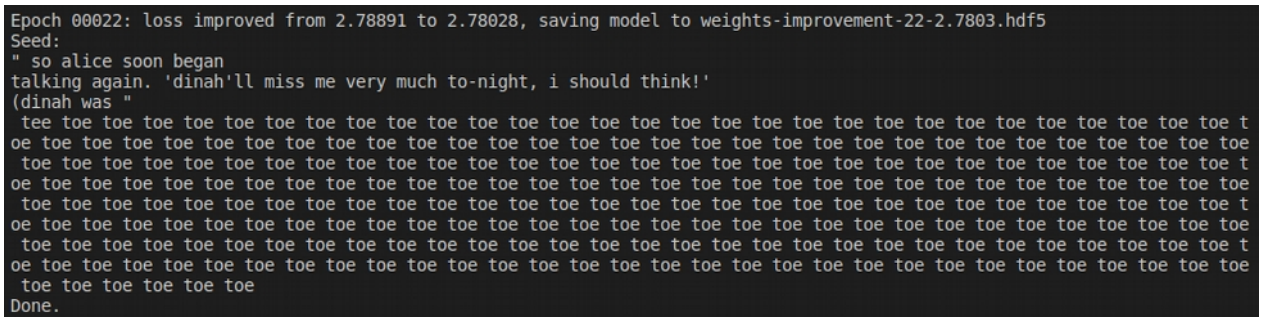

После 30 эпохи в сгенерированном тексте присутствуют уже 3 уникальных слова.

```
Epoch 00030: loss improved from 2.69971 to 2.68874, saving model to weights-improvement-30-2.6887.hdf5
Seed:
"  cats eat bats, i wonder?' and here alice
began to get rather sleepy, and went on saying to herself, "
 th the woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe wo
e woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe
woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe wo
e woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe
woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe wo
e woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe
woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe wo
e woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe woe
woe woe woe woe woe woe
Done.
```

Обучать сеть на большем количестве эпох оказалось затруднительно, это связано с тем, что обучение происходит слишком долгое время. К примеру, для 30 эпох потребовалось бы более 10 часов. Поэтому текст было решено обрезать до 116 строк. Но даже из получившихся результатов можно заметить, что с увеличением эпох уменьшается количество повторений и появляется всё больше осмысленных слов.

Выводы.

В ходе выполнения лабораторной работы была построена и обучена нейронная сеть, которая позволяет генерировать текст на основе произведения Льюиса Кэрролла «Приключения Алисы в Стране Чудес». Был также написан собственный CallBack, позволяющий отслеживать прогресс сети. В результате своего обучения сеть смогла генерировать неосмысленные тексты, в которых порой встречаются существующие слова.

ПРИЛОЖЕНИЕ А

```
import numpy
from keras.callbacks import Callback
from keras.models import Sequential
from keras.layers import Dense
from keras.layers import Dropout
from keras.layers import LSTM
from keras.callbacks import ModelCheckpoint
from keras.utils import np_utils
from os import listdir
from os import path

class Mycallback(Callback):
def __init__(self, epochs):
super(Mycallback, self).__init__()
self.epochs = epochs

def on_epoch_end(self, epoch, logs=None):
if epoch in self.epochs:
random_generate(self.model, epoch)

def random_generate(_model, epoch=0):
start = numpy.random.randint(0, len(dataX) - 1)
pattern = dataX[start]
print("Seed:")
print("\"", ''.join([int_to_char[value] for value in pattern]), "\"")
text = []
for i in range(1000):
x = numpy.reshape(pattern, (1, len(pattern), 1))
x = x / float(n_vocab)
prediction = _model.predict(x, verbose=0)
index = numpy.argmax(prediction)
result = int_to_char[index]
text.append(result)
print(result, end='')
pattern.append(index)
pattern = pattern[1:len(pattern)]
```

```
print("\nDone.")
with open('text_{}.txt'.format(epoch), 'w') as file:
file.write(''.join(text))

filename = "wonderland.txt"
raw_text = open(filename).read()
raw_text = raw_text.lower()
chars = sorted(list(set(raw_text)))
char_to_int = dict((c, i) for i, c in enumerate(chars))
int_to_char = dict((i, c) for i, c in enumerate(chars))
n_chars = len(raw_text)
n_vocab = len(chars)
print("Total Characters: ", n_chars)
print("Total Vocab: ", n_vocab)
seq_length = 100
dataX = []
dataY = []

for i in range(0, n_chars - seq_length, 1):
seq_in = raw_text[i:i + seq_length]
seq_out = raw_text[i + seq_length]
dataX.append([char_to_int[char] for char in seq_in])
dataY.append(char_to_int[seq_out])

n_patterns = len(dataX)
print("Total Patterns: ", n_patterns)

X = numpy.reshape(dataX, (n_patterns, seq_length, 1))
X = X / float(n_vocab)
y = np_utils.to_categorical(dataY)

model = Sequential()
model.add(LSTM(256, input_shape=(X.shape[1], X.shape[2])))
model.add(Dropout(0.2))
model.add(Dense(y.shape[1], activation='softmax'))
model.compile(loss='categorical_crossentropy', optimizer='adam')
```

```
filepath = "weights-improvement-{epoch:02d}-{loss:.4f}.hdf5"
checkpoint = ModelCheckpoint(filepath, monitor='loss', verbose=1, save_best_only=True, mode='min')
callbacks_list = [checkpoint, Mycallback([6, 11, 21, 29])]

model.fit(X, y, epochs=30, batch_size=128, callbacks=callbacks_list)

folder = '.'
filename = ''
min = 999999
for name in listdir(folder):
full_name = path.join(folder, name)
if path.isfile(full_name) and full_name.find('.hdf5') != -1:
model_loss = int(full_name.split('.')[2])
if min > model_loss:
min = model_loss
filename = full_name

print(filename)
model.load_weights(filename)
model.compile(loss='categorical_crossentropy', optimizer='adam')
random_generate(model)
```